BENCHMARK / V2 · 2026-10-29

GPU Inference Comparison Baseline · aiDAPTIV · LMCache

GPT-OSS-20B ｜ 3 模式 × 8 情境 × 4 次 ＝ 96 筆

實驗目的與測試方式

Purpose · Method & Parameters

實驗目的

比較 **aiDAPTIV**、**LMCache** 相對 **Baseline**（無 KV 快取），以及 **LMCache 相對 aiDAPTIV** 的 TTFT、TPOT、TPS 差異。

測試方式及參數

每個情境送**同一組 Prompt**：**KV Cold** 1 次（快取空）→ **KV Warm** 3 次（快取已有）；測試 **TTFT** 首字延遲、**TPOT** 字間隔、**TPS** 每秒輸出。

Model 模型
GPT-OSS-20B

Context 上限
20,000 tokens

Input 輸入
3,950 / 7,950 / 15,950 tokens
約等於 4K / 8K / 16K

Output 輸出
200 tokens

Concurrency 並發
1 / 2 / 5

測試參數參照群聯提供之 benchmark 腳本

結論｜KV Warm

KV Cache reuse

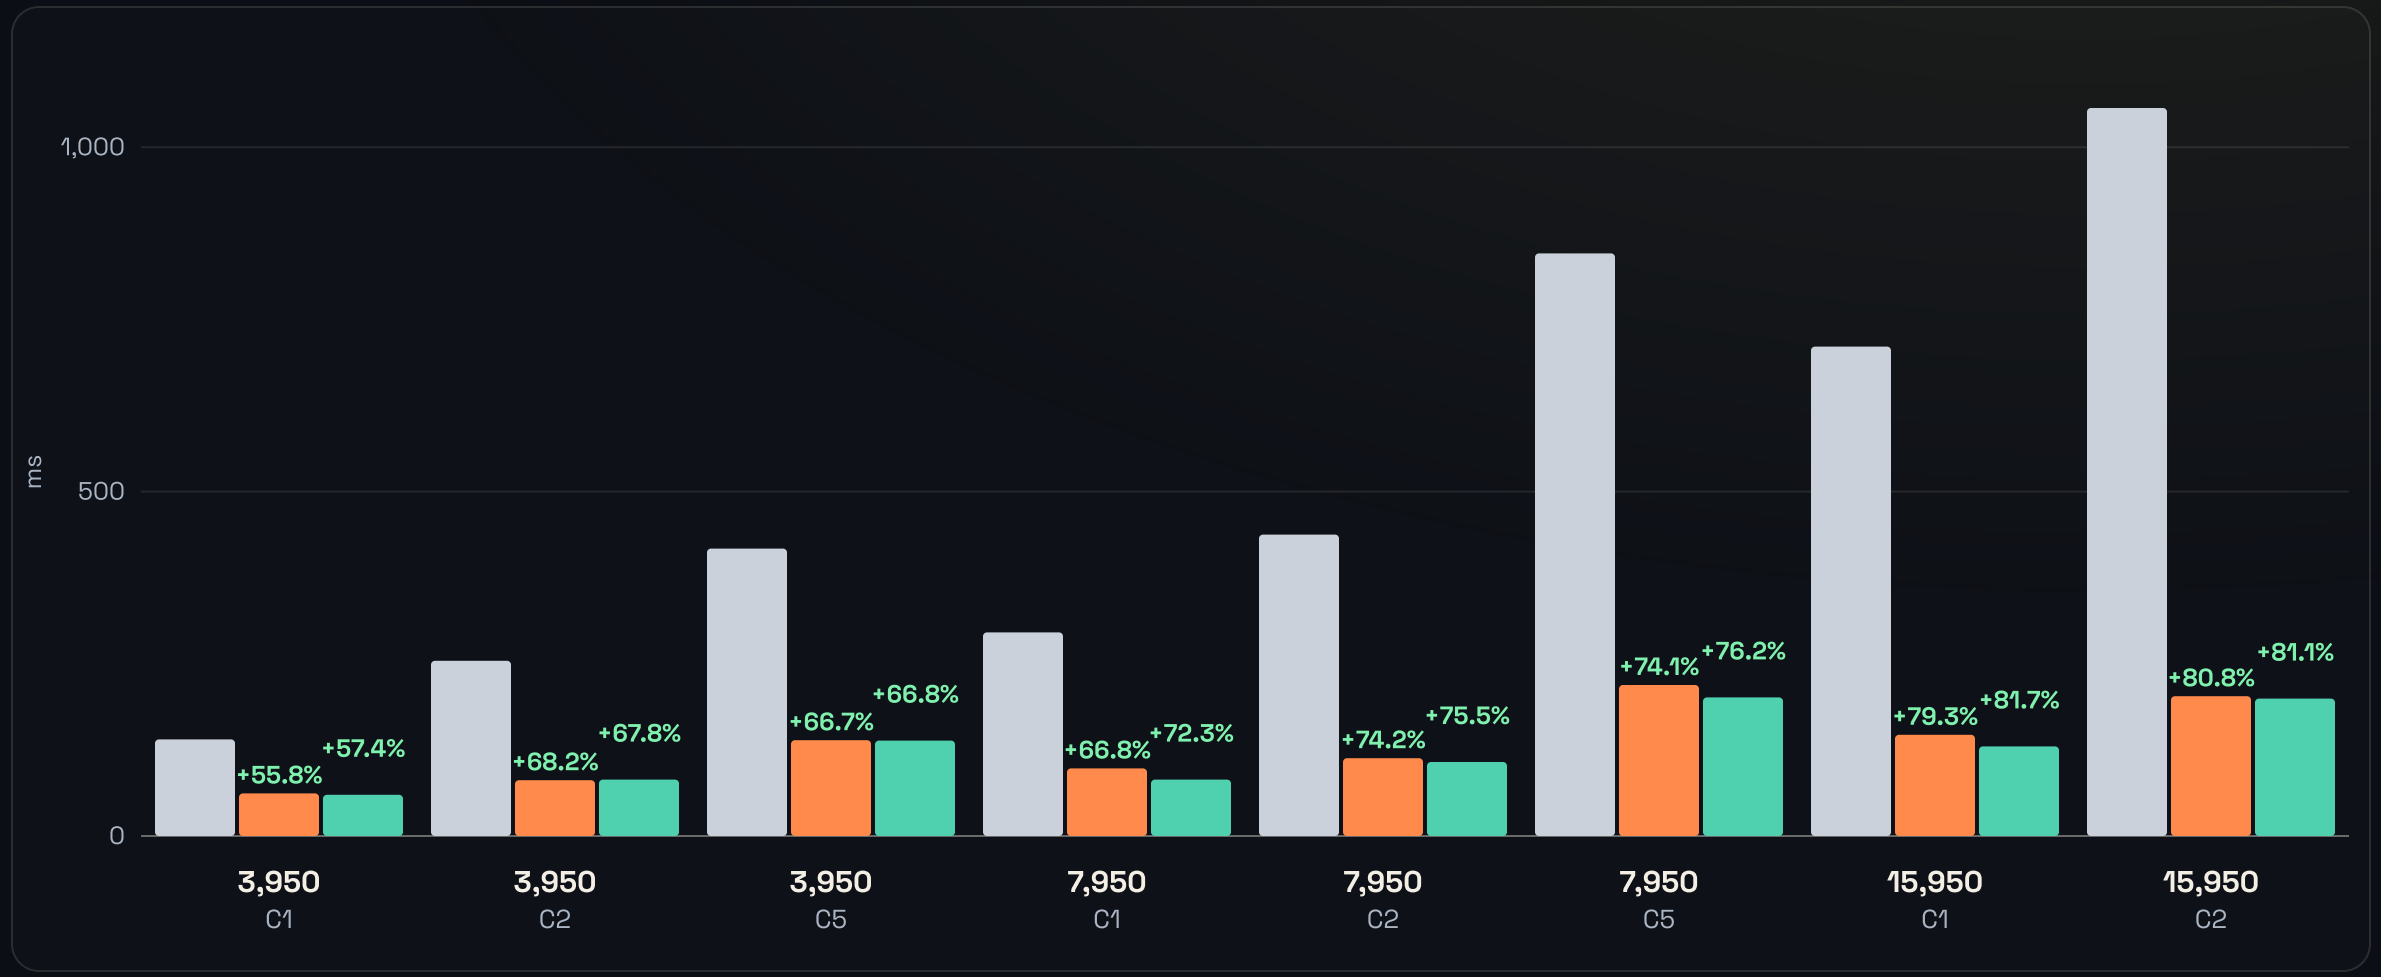
	aiDAPTIV 相對 Baseline	LMCache 相對 Baseline	LMCache 相對 aiDAPTIV
TTFT 首字延遲 · 越低越好 ↓	+70.7%	+72.3%	+5.7%
TPOT 每個字的間隔 · 越低越好 ↓	+4.6%	+26.0%	+22.5%
TPS 每秒輸出 token · 越高越好 ↑	+29.2%	+64.1%	+26.6%

相較 Baseline（無 aiDAPTIV），aiDAPTIV 與 LMCache 都大幅降低 TTFT（首字延遲）：+70.7% / +72.3%。

LMCache 在 TPOT、TPS 上更遠勝 aiDAPTIV：TPOT +26.0% vs +4.6%，TPS +64.1% vs +29.2%。

TTFT 首字延遲｜KV Warm

↓ 越低越好　開啟 aiDAPTIV 或 LMCache 後效果皆遠優於 Baseline，同時 LMCache 平均優於 aiDAPTIV 5.7%



TTFT 首字延遲｜KV Warm 數據

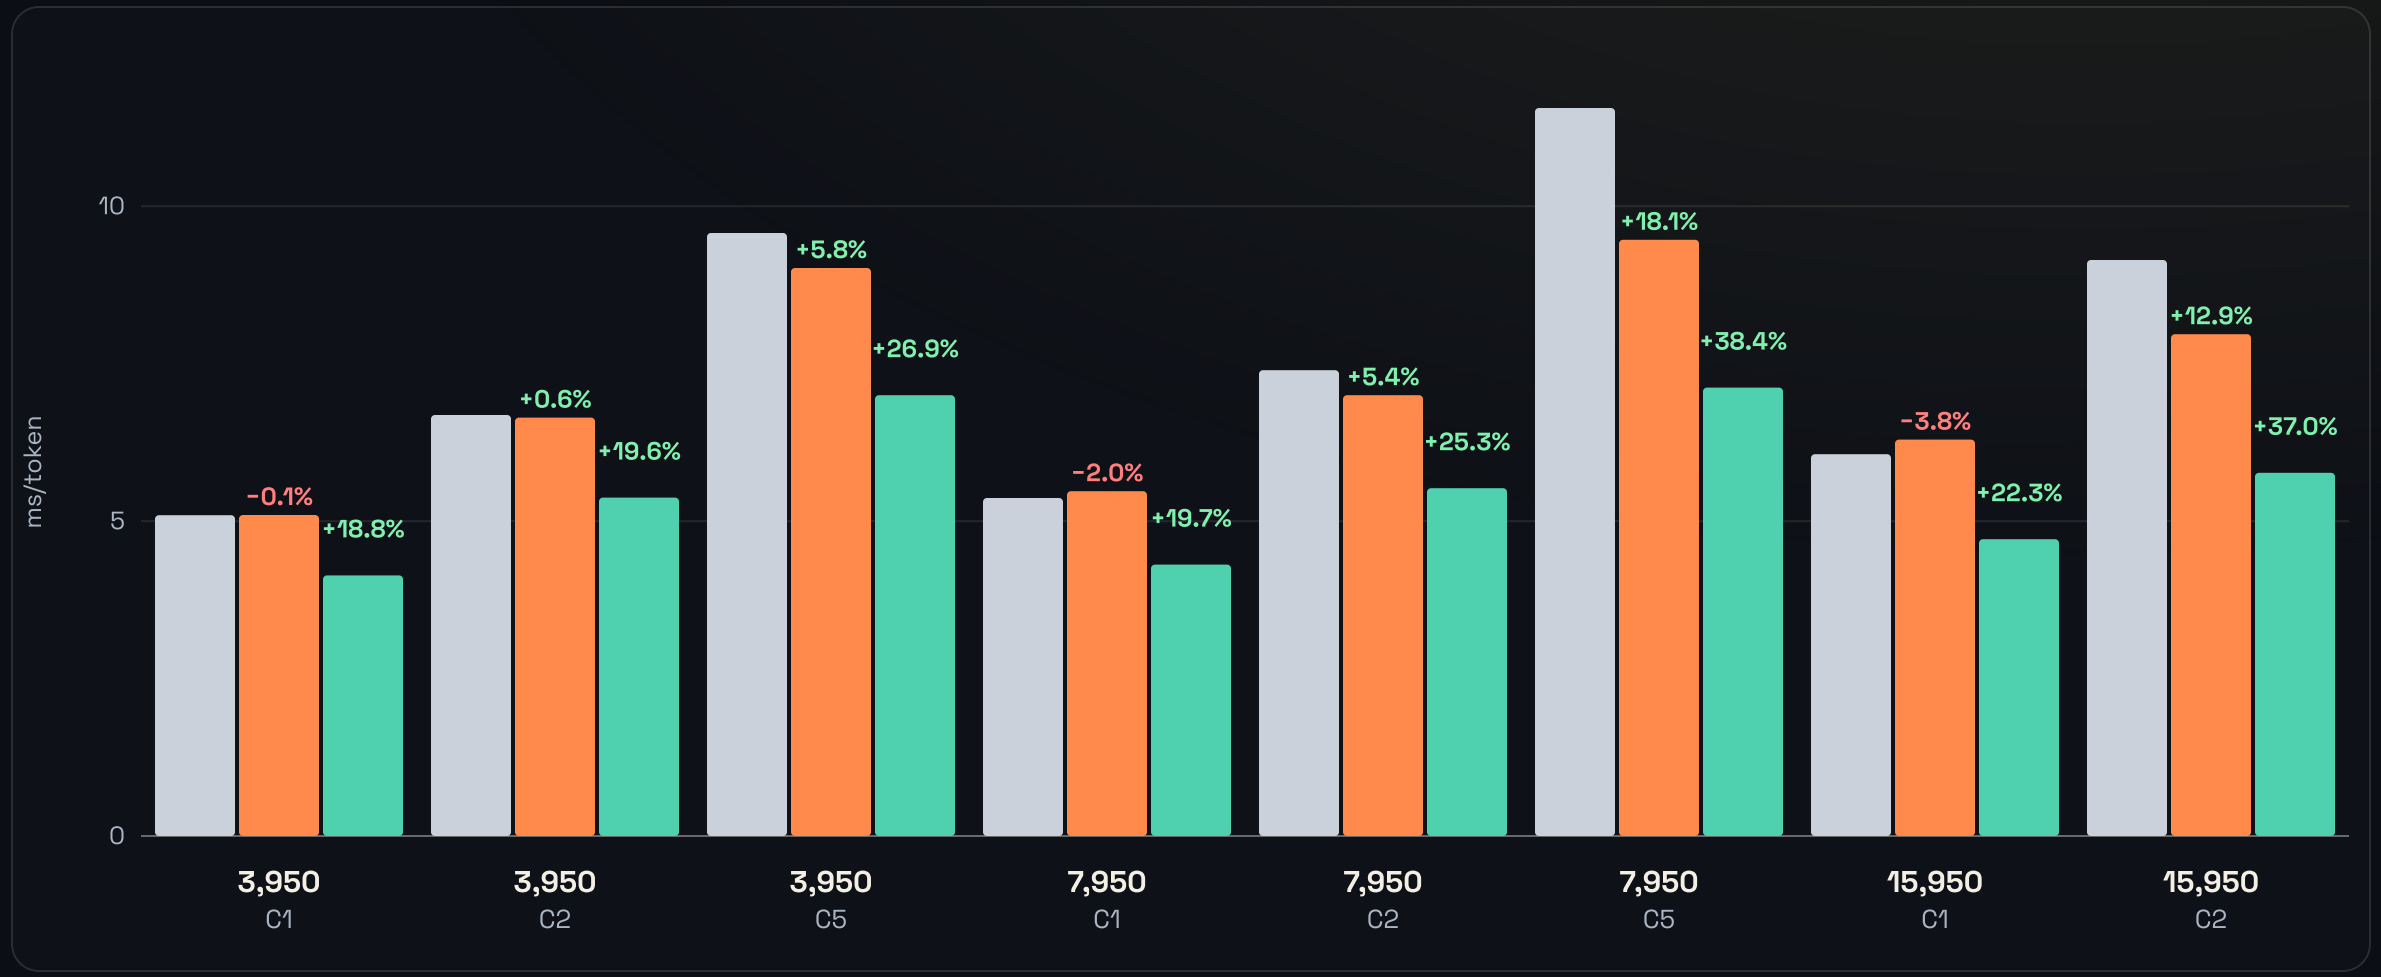
TTFT 比較中 LMCache 平均優於 aiDAPTIV 5.7%

Input	C	Baseline	aiDAPTIV ON	vs Baseline	LMCache	vs Baseline	LMCache vs aiDAPTIV
3,950	C1	140.20	**61.97**	+55.8%	**59.67**	+57.4%	+3.7%
3,950	C2	254.20	**80.87**	+68.2%	**81.93**	+67.8%	-1.3%
3,950	C5	417.20	**139.07**	+66.7%	**138.53**	+66.8%	+0.4%
7,950	C1	295.53	**98.00**	+66.8%	**82.00**	+72.3%	+16.3%
7,950	C2	437.57	**112.83**	+74.2%	**107.37**	+75.5%	+4.8%
7,950	C5	845.70	**219.10**	+74.1%	**201.07**	+76.2%	+8.2%
15,950	C1	710.50	**146.77**	+79.3%	**130.00**	+81.7%	+11.4%
15,950	C2	1,056.80	**203.03**	+80.8%	**199.47**	+81.1%	+1.8%
All Scenario average differential 全情境平均差異				**+70.7%**		**+72.3%**	**+5.7%**

TPOT 每個字的間隔｜KV Warm

↓ 越低越好　高 Concurrency（C5）比較中，LMCache 與 aiDAPTIV 各自優於 Baseline 32.7%, 12.0%；LMCache 優於 aiDAPTIV 23.6%

Baseline　aiDAPTIV ON　LMCache



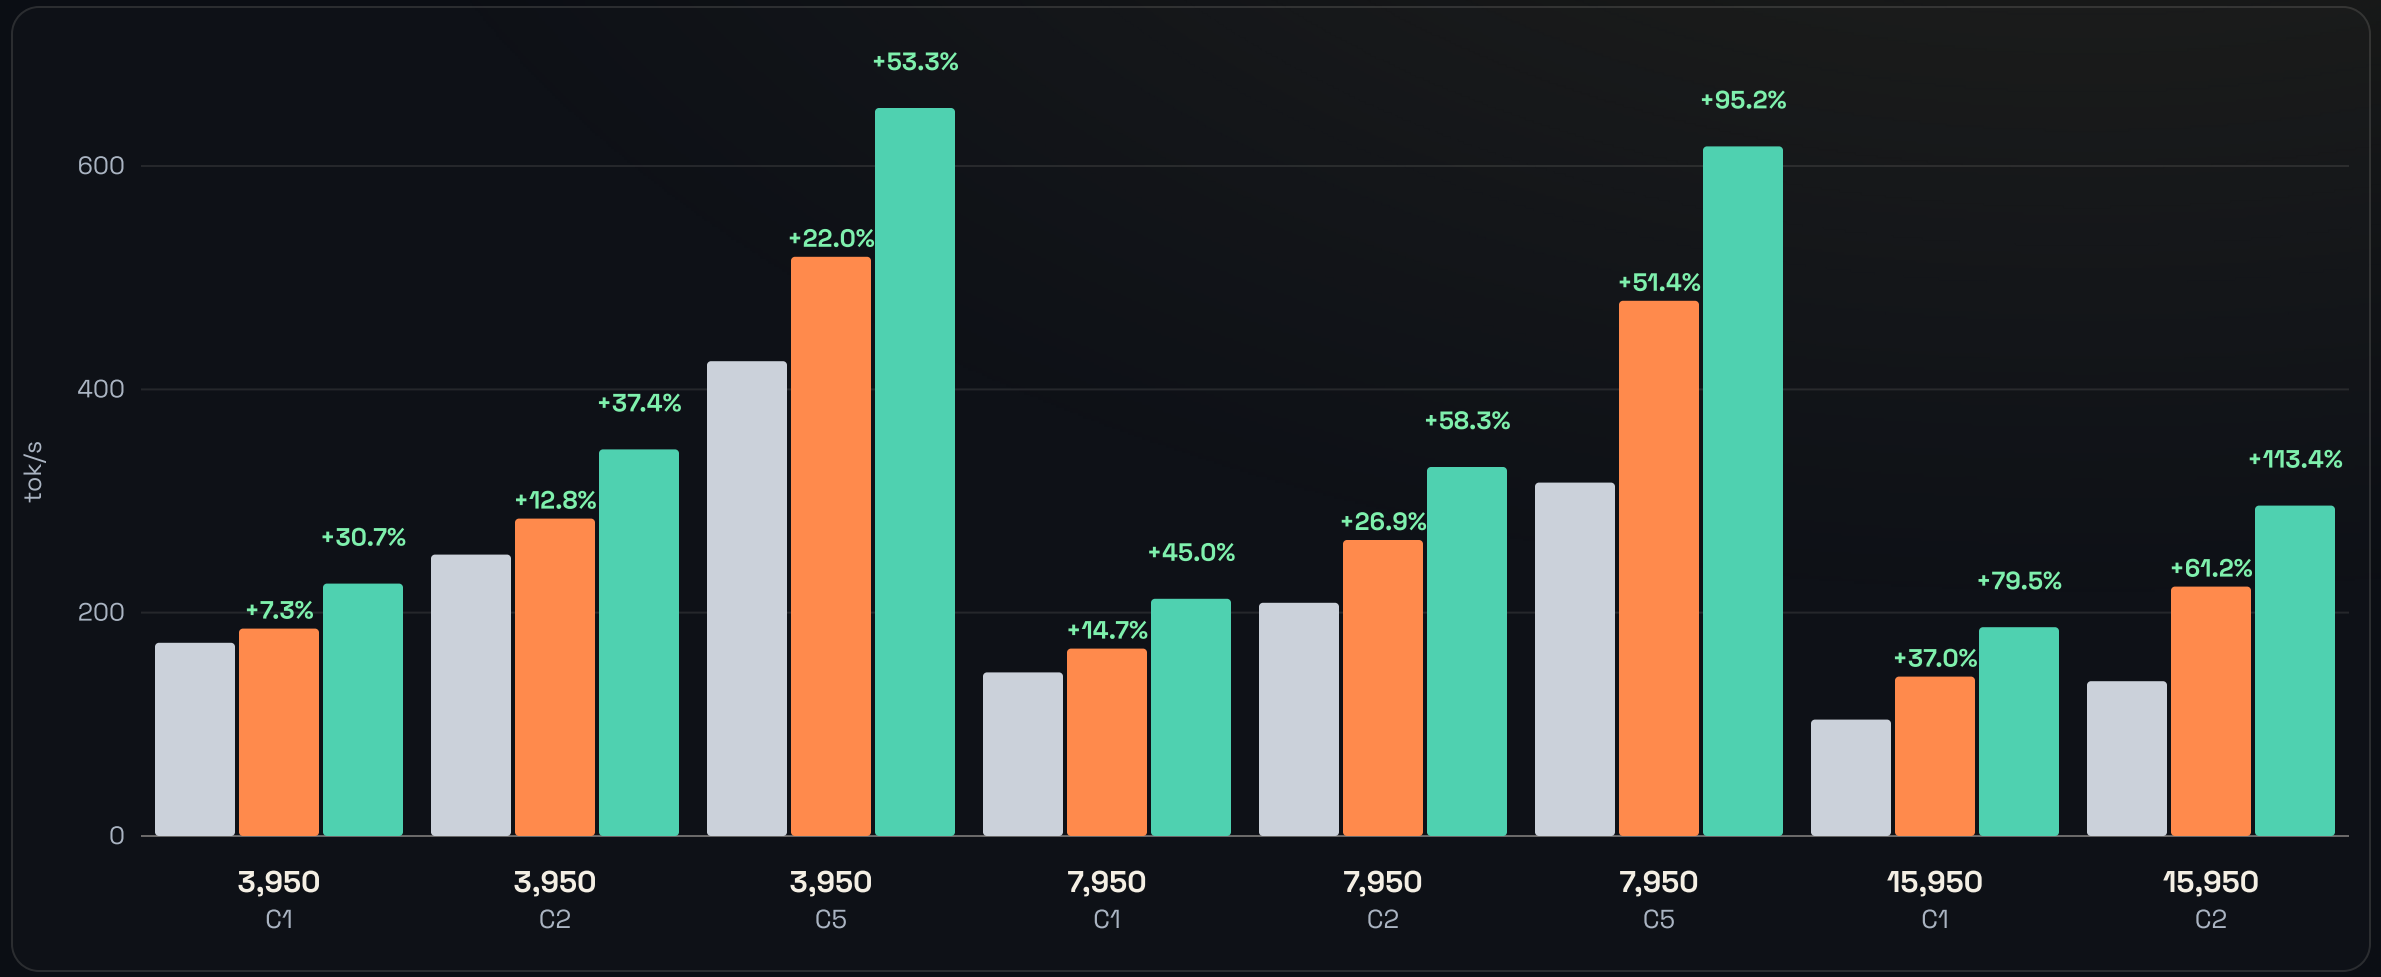
TPOT 每個字的間隔｜KV Warm 數據

TPOT 比較中 LMCache 平均優於 aiDAPTIV 22.5%

Input	C	Baseline	aiDAPTIV ON	vs Baseline	LMCache	vs Baseline	LMCache vs aiDAPTIV
3,950	C1	5.09	**5.10**	−0.1%	**4.14**	+18.8%	+18.8%
3,950	C2	6.69	**6.64**	+0.6%	**5.37**	+19.6%	+19.1%
3,950	C5	9.58	**9.02**	+5.8%	**7.00**	+26.9%	+22.4%
7,950	C1	5.37	**5.48**	−2.0%	**4.31**	+19.7%	+21.3%
7,950	C2	7.40	**7.00**	+5.4%	**5.52**	+25.3%	+21.1%
7,950	C5	11.56	**9.47**	+18.1%	**7.12**	+38.4%	+24.8%
15,950	C1	6.06	**6.29**	−3.8%	**4.71**	+22.3%	+25.1%
15,950	C2	9.15	**7.97**	+12.9%	**5.77**	+37.0%	+27.6%
All Scenario average differential 全情境平均差異				**+4.6%**		**+26.0%**	**+22.5%**

TPS 每秒輸出 token｜KV Warm

↑ 越高越好　LMCache 平均 TPS 在 4K、8K、16K 分別較 aiDAPTIV 快出 23.1%、26.7%、31.7%



TPS 每秒輸出 token｜KV Warm 數據

TPS 比較中 LMCache 平均優於 aiDAPTIV 26.6%

Input	C	Baseline	aiDAPTIV ON	vs Baseline	LMCache	vs Baseline	LMCache vs aiDAPTIV
3,950	C1	173.0	**185.7**	+7.3%	**226.0**	+30.7%	+21.7%
3,950	C2	252.0	**284.3**	+12.8%	**346.2**	+37.4%	+21.8%
3,950	C5	425.1	**518.7**	+22.0%	**651.9**	+53.3%	+25.7%
7,950	C1	146.4	**167.9**	+14.7%	**212.4**	+45.0%	+26.5%
7,950	C2	208.8	**265.1**	+26.9%	**330.5**	+58.3%	+24.7%
7,950	C5	316.4	**479.2**	+51.4%	**617.5**	+95.2%	+28.9%
15,950	C1	104.2	**142.8**	+37.0%	**187.0**	+79.5%	+31.0%
15,950	C2	138.6	**223.4**	+61.2%	**295.8**	+113.4%	+32.4%
All Scenario average differential 全情境平均差異				**+29.2%**		**+64.1%**	**+26.6%**

KV Cold（第一次請求）

即便在 KV Cold，LMCache 在 TPOT、TPS 仍優於 aiDAPTIV：TPOT +25.3%、TPS +18.0%；TTFT 則慢 11.8%

	aiDAPTIV 相對 Baseline	LMCache 相對 Baseline	LMCache 相對 aiDAPTIV
TTFT 首字延遲	-22.7%	-38.1%	-11.8%
TPOT 每個字的間隔	-3.9%	+22.4%	+25.3%
TPS 每秒輸出 token	-6.8%	+9.9%	+18.0%

第一次請求需 offload 到 DRAM 與 SSD，各項數據慢於 Baseline 屬正常現象；即便如此，LMCache 平均在 TPOT、TPS 的表現仍皆優於 Baseline 與 aiDAPTIV。

Cache hit tokens｜快取命中（KV Warm）

aiDAPTIV 在 Hit tokens 命中數上小幅優於 LMCache，平均約 1.0%

Input	C*	Prompt tokens	aiDAPTIV ON External hit	LMCache External hit	LMCache vs aiDAPTIV 命中數差異
3,950	C1	3,950	**3,936** 99.6%	**3,840** 97.2%	-2.4%
3,950	C2	7,900	**7,872** 99.6%	**7,680** 97.2%	-2.4%
3,950	C5	19,750	**19,680** 99.6%	**19,200** 97.2%	-2.4%
7,950	C1	7,950	**7,936** 99.8%	**7,936** 99.8%	0.0%
7,950	C2	15,900	**15,872** 99.8%	**15,872** 99.8%	0.0%
7,950	C5	39,750	**39,680** 99.8%	**39,680** 99.8%	0.0%
15,950	C1	15,950	**15,936** 99.9%	**15,872** 99.5%	-0.4%
15,950	C2	31,900	**31,872** 99.9%	**31,744** 99.5%	-0.4%
All Scenario average differential 全情境平均差異					**-1.0%**

* C = 並發數，一次測試同時送出 C 個請求